

Verifica ipotesi

Sunday, 14 May 2023

16:34

- Ogni qualvolta che noi facciamo dei test sui parametri, noi stiamo facendo dei test parametrici (però esistono anche test non parametrici)

- o Fatta ipotesi statistica bisogna controllare se è compatibile col campione

T_1 = ipotesi alternativa

T_0 = ipotesi nulla -> Rifiutata se risulta incompatibile con i dati del campione

Bisogna trovare una regola, e la regola è basata sulla statistica (che deciderà)

-> Statistica del test

Bisogna trovare una regione critica (aka regione di rifiuto) dove rifiuto se

I dati campionari stanno in c ($x_1 \dots x_n$) $\in c$

Gli errori che possiamo avere sono di 2 tipi:

- o Prima specie: Si rifiuta H_0 ed H_0 è vera
- o Seconda specie: Si accetta H_0 ed H_0 è falsa

Aka rifiuto H_1 ed è vera

E noi vogliamo cercare di rendere piccoli sia gli errori di prima e seconda specie

Però, rendendo più piccolo l'errore di prima specie, diminuiamo la regione critica

E questo vuol dire che forse avremmo più errori di seconda specie

Ciò che si fa è creare un $\alpha = 0.1, 0.05, 0.01$

E noi vogliamo far sì che $H_0 \leq \alpha$

$$P_{H_0}((x_1, \dots, x_n) \in c) \leq \alpha$$

- Si suppone

$$N(m, \sigma^2)$$

$$H_0: m = m_0$$

$$H_1: m \neq m_0$$

E noi vogliamo che

$$|\bar{x}_n - m| > c$$

$$C = \{(x_1, \dots, x_n) \in R^n: |\bar{x}_n - m_0| > c\}$$

E bisogna trovare c con

$$P_{m_0}(|\bar{x}_n - m_0| > c) = \alpha$$

Con un pò di magia

$$P_{m_0}\left(\sqrt{n} * \frac{\bar{x}_n - m_0}{\sigma} > \frac{c\sqrt{n}}{\sigma}\right) = \alpha$$

(Così facendo abbiamo una normale standard)

E con altre magie

$$\left|\sqrt{n} * \frac{\bar{x}_n - m_0}{\sigma}\right| > z_\alpha \rightarrow (|z| > z_\alpha)$$

$$\left| \frac{\bar{x} - m_0}{\frac{\sigma}{\sqrt{n}}} \right| \leq z_{\frac{\alpha}{2}}$$

E quindi il nostro intervallo diventa

$$\left(\bar{x}_n \pm \frac{\sigma}{\sqrt{n}} * z_{\frac{\alpha}{2}} \right)$$

Qui invece errore secondo tipo (credo?)

$$\bar{\alpha} = 2 \left(1 - \phi \left(\left| \frac{\bar{x}_n - m_0}{\frac{\sigma}{\sqrt{n}}} \right| \right) \right)$$

[Mi manca l'altro prof]

- Abbiamo 2 casi:

- $H_0: m = m_0, \quad H_1: m > m_0$
- $H_0: m = m_0, \quad H_1: m < m_0$

In questi casi noi sappiamo che

$$\frac{\bar{x}_n - m_0}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

Si rifiuta se

$$z = \sqrt{n} * \frac{\bar{x}_n - m_0}{\sigma} > z_{\alpha}$$

Aka rifiuto H_0 a livello di α se $m_0 \notin \left(\bar{x}_n - z_{\alpha} * \frac{\sigma}{\sqrt{n}}, +\infty \right)$

E questo è l'estremo inferiore di confidenza

$$\bar{\alpha} = 1 - \phi \left(\frac{\bar{x}_n - m_0}{\frac{\sigma}{\sqrt{n}}} \right)$$

(Mi sto rompendo di sta prof, giuro non riesco a seguirla)

Mi aspetto di rifiutare se

L'unico fatto da ricordare è che

$$z_{1-\alpha} = -z_{\alpha}$$

- Test per la media di una popolazione normale con varianza incognita

$$T := \frac{\bar{x}_n - m_0}{\frac{S_n}{\sqrt{n}}} \sim t_{n-1}$$

- Test di una proporzione (grandi campioni)

Si vuole sottoporre

$$h_0: p = p_0 \text{ vs } h_1: p \neq p_0$$

E supponiamo che il campione $\sim Be(p)$

Quindi sappiamo che

$$E(X) = p$$

$$X = p(1 - p)$$

Formula: se

$$n \geq 30$$

$$np_0 > 5$$

$$n(1 - p_0) > 5$$

Allora possiamo supporre che $X \sim N(0, 1)$

E quindi possiamo usare le regioni critiche del test Z

H_0	H_1	Statistica	Regione critica
$p = p_0$	$p \neq p_0$	$Z = \frac{\bar{X}_n - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n}$	$\left \frac{\bar{x}_n - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n} \right > z_{\alpha/2}$
$p \leq p_0$	$p > p_0$	$Z = \frac{\bar{X}_n - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n}$	$\frac{\bar{x}_n - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n} > z_{\alpha}$
$p \geq p_0$	$p < p_0$	$Z = \frac{\bar{X}_n - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n}$	$\frac{\bar{x}_n - p_0}{\sqrt{p_0(1-p_0)}} \sqrt{n} < -z_{\alpha}$

- Varianza campionaria combinata:

$$S_p^2 = \frac{(n_x - 1)S_x^2 + (n_y - 1)S_y^2}{n_x + n_y - 2}$$

H_0	H_1	Statistica	Regione critica
$\mu_x = \mu_y$	$\mu_x \neq \mu_y$	$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}}$	$\left \frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}} \right > t_{n_x + n_y - 2, \alpha/2}$
$\mu_x \leq \mu_y$	$\mu_x > \mu_y$	$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}}$	$\frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}} > t_{n_x + n_y - 2, \alpha}$
$\mu_x \geq \mu_y$	$\mu_x < \mu_y$	$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}}$	$\frac{\bar{x} - \bar{y}}{s_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}} < -t_{n_x + n_y - 2, \alpha}$

- Test non parametrici

Basta mi arrendo a seguire sta prof

Con tutto il mio impegno non riesco a comprenderla, una dei prof peggiori di quest'anno scolastico. Mi sembra di star ascoltando un muro.

Apro gli appunti di quack e vaffanculo.

E leggo il pdf, non riesco più ad ascoltare la voce della prof, mi genera nervoso e fa

- Esercizio teorico dal pdf

Da un comune, dopo una votazione sono usciti i seguenti risultati

Partito	A1	A2	A3	A4
%	32	26	16	25

In un altro comune,

Abbiamo avuto in totale 320 voti con i seguenti risultati

Partito	A1	A2	A3	A4
Num	118	71	62	69

Uniamo le tabelle trasformando

Le percentuali in valori ($N * x_i$)

Partito	A1	A2	A3	A4
Num	118	71	62	69

num	110	71	52	80
%-> f_i	102.4	86.4	51.2	80

Ora per ogni valore calcoliamo lo squarto quadratico

$$Q = \sum \frac{(n_i - f_i)^2}{f_i} \sim \chi^2(N - 1) = 8.91$$

Scegliamo $q = 8.91$

Si rifiuta se

$$q > \chi^2_{n-1, \alpha} \rightarrow 8.91 > 7.815$$

Quindi rifiutiamo

- Dati infiniti

Gli incidenti seguono una legge $P_0(0, 4)$

E nelle ultime 85 settimane sono stati riletavi:

N incidenti	0	1	2	3+
N settimane	50	32	3	0

Si può affermare che il modello è ancora verificabile?

$$N=85$$

$$Y \sim P_0(0.4)$$

Calcoliamo ora la frequenza della poisson

$$f_0 = P(Y = 0) = \frac{e^{-0.4}(0.4)^k}{k!} = e^{-0.4} = 0.67$$

Ed il nostro valore esce come

$$n_0 = n * f_0 = 56.95$$

$$n_1 = 21.78$$

$$n_2 = 4.59$$

$$f_3 = P(Y \geq 3) = 1 - \sum_{i=0}^2 P(Y = i)$$

$$= 0.008$$

$$n_3 = 0.68$$

Mettiamo questi valori nella tabella di sopra

N incidenti	0	1	2	3+
N settimane	50	32	3	0
n_i	56.95	22.79	4.59	0.68

Notiamo che 2, 3 non seguono la regola empirica che dice che

Se il valore è inferiore di 5 allora non può essere usato.

Quindi dobbiamo accorporare 2 e 3

N incidenti	0	1	2+
-------------	---	---	----

N settimane	50	32	3
n_i	56.95	22.79	5.27

Ora usiamo la formula

$$Q = \sum \frac{(N_i - f_i)^2}{f_i} = 5.5576$$

Dato $\alpha = 5\%$

$$q > X_{2,0.05}^2$$

$$5.5576 > 5.991 \rightarrow \text{rifiuto } h_0$$

- Esercizio variabile continua

I tempi di vita di 100 lampadine estratte casualmente è come segue

Tempo vita	N lampadine
>1	24
1-2	16
2-3	20
3-4	14
4-5	10
5-10	16
10+	0

Si può affermare che il tempo di vita segue una legge esponenziale?

$$h_0: \exp(\lambda)$$

$$Y \sim \text{Exp}(\lambda)$$

$$E(Y) = \frac{1}{\lambda}$$

E sappiamo che $E(Y)$ è stimato con \bar{x}_n

E quindi

$$\lambda \text{ stimato con } \frac{1}{\bar{x}_n}$$

Approfondiamo la tabella cercando il punto medio dei dati

Il punto medio dei dati è

$$\text{Tra } 0 \text{ e } 1 = 0.5$$

$$\text{Tra } 1 \text{ e } 2 = 1.5$$

$$\text{Es. } 1 \text{ e } 3 = 2$$

Ora guardiamo la tabella in sè per sè

Tempo vita T_i	Punto medio \bar{x}_i	N lampadine
>1	0.5	24
1-2	1.5	16
2-3	2.5	20
3-4	3.5	14
4-5	4.5	10
5-10	7.5	16
10+	15	0

2-3	2.5	20
3-4	3.5	14
4-5	4.5	10
5-10	7.5	16
10+	3	0

Il punto medio per valori verso infinito si fa

$$\bar{x}_{100} = \frac{1}{n} * \sum T_i * x_i = \frac{1}{100} * (0.5 * 24 + 2.5 * 16 + 2.5 * 20 + \dots) = \frac{1}{100} * 300 =$$

Ora quindi possiamo calcolare

$$\lambda = \frac{1}{\bar{x}} = \frac{1}{3} = 0.33$$

(Il valore di sopra)

Ora dobbiamo calcolare le frequenze attese

$$P(Y < 1) = P(y = 1) = 1 - e^{-\lambda y} = 1 - e^{-0.33*1} = 0.2811 = \pi_1$$

$$P(1 \leq y < 2) = e^{-0.33} - e^{-0.33*2} = 0.2021 = \pi_2$$

$$P(3 \leq y < 4) = \dots = 0.1044 = \pi_3$$

$$P(4 \leq y < 5) = \dots = 0.0751 = \pi_4$$

$$P(5 \leq Y < 10) = \dots = 0.1552 = \pi_5$$

$$P(Y \geq 10) = 1 - P(Y \leq 10) = 0.0369 = \pi_6$$

Quindi, rifiuto h_0 se

$$q = \sum_{i=1}^7 \frac{(n_i - f_i)^2}{f_i} > X_{n-1-1, \alpha}^2$$

- Si chiede se il seguente segue la legge di Poisson.

Incidenti settimana	0	1	2	3+
Verificato	50	32	3	0

$$H_0: Y \sim P_0(\lambda), \quad E(Y) = \lambda$$

$$\lambda = \bar{x}_{85} = \frac{0 * 50 + 1 * 32 + 2 * 3}{85} = 0.447 = E(Y)$$

Quindi con questo possiamo calcolare

$$P(Y = 0) = e^{-0.447} = 0.64 = \pi_0 \rightarrow f_0 = 85 * 0.64 = 54.4$$

$$P(Y = 1) = e^{-0.447} * 0.447 = 0.29 = \pi_1 \rightarrow f_1 = 85 * 0.29 = 24.65$$

$$P(Y = 2) = e^{-0.447} * \left(\frac{0.447}{2}\right)^2 = 0.06 = \pi_2 \rightarrow f_2 = 85 * 0.06 = 5.1$$

$$P(Y \geq 3) = 1 - P(Y \leq 2) = 1 - (\pi_0 + \pi_1 + \pi_2) = 0.01 = \pi_3 \rightarrow f_3 = 0.85$$

Per via della regola empirica, devo unire π_3 con π_2

Siccome $f_3 < 1$

Incidenti settimana	0	1	2+
---------------------	---	---	----

Incidenti settimanali	0	1	2+
Frequenze assolute	50	32	3
Frequenze attese	56.4	26.65	5.95

Quindi dobbiamo calcolare Q ora

$$Q = \sum \frac{(n_i - f_i)^2}{f_i} \sim \chi^2_{N-1-?} = \chi^2(1)$$

$q = \dots$

Scelgo $\alpha = 5\% \rightarrow \alpha = 0.05$

$$q > \chi^2_{1,0.05}$$

Minchia ragazzi non c'ho capito na beata minchia

Esempio:

1) $N(m, 2^2), m = ?$

Abbiamo $n=10$

E $\bar{x}_{10} = 18.58$

a. Si verifica che $H_0: m = 20$

Con $\alpha = 5\%$

Applichiamo il test Z

$$Z = \sqrt{n} * \frac{\bar{x}_n - m_0}{\sigma} \sim N(0, 1)$$

E qui rifiuto se

$$|z| > z_{\frac{\alpha}{2}} = z_{0.025} = 1.96$$

$$|z| = \left| \frac{18.58 - 20}{2} \sqrt{10} \right| = 2.24 > 1.96$$

E rifiutiamo siccome $\alpha = 5\%$

Se avessimo $\alpha = 10\%$

Sappiamo per certezza che rifiutiamo siccome, aumentando α noi avremo un più alto per rifiutare h_0

Per $\alpha = 1\%$ dobbiamo fare i calcoli

b. Ora invece abbiamo $m=21$

Siccome $21 \neq 20$

$$P_{m=21} = \left(\left| \sqrt{10} * \frac{\bar{x}_n - 20}{2} \right| < z_{0.025} \right)$$

Qui abbiamo il problema che, dovremmo avere

$$\frac{\bar{x}_n - 21}{\frac{\sigma}{\sqrt{n}}}$$

Però noi abbiamo -20

Allora bisogna far comparire il 21 con tanti calcoli

$$P = \left(-1.96 < \sqrt{10} * \frac{\bar{x}_n - 20}{2} < 1.96 \right)$$

$$P = \left(-1.96 - \frac{\sqrt{10}}{2} < \sqrt{10} * \frac{\bar{x}_n - 21}{2} < 1.96 - \frac{\sqrt{10}}{2} \right)$$

Quindi ora $\sim N(0, 1)$

$$P = (-3.54 < z < 0.37) = \phi(0.37) - \phi(-3.54)$$

$$P = 0.6443$$

2) Si scelgono casualmente 64 bambini, e dopo averli misurati

$$\bar{x} = 106$$

La media italiana = 106

Si suppone che il QI $N(m, 256)$

Quindi abbiamo $\sigma^2 = 256$

Quindi

$$N=64$$

$$\bar{x}_n = 106$$

$$\sigma = 16$$

- Con $\alpha = 0.025$ sono i suoi studenti più intelligenti della media?

Quindi vuole concludere che $m > 100$

Nella nostra relazione $N(m, 256)$

Iniziamo a calcolare

$$z = \frac{\bar{x}_n - m_0}{\frac{\sigma}{\sqrt{n}}} = 3$$

Si rifiuta se

$$\frac{\bar{x}_n - m_0}{\frac{\sigma}{\sqrt{n}}} > z_{\alpha} \rightarrow 3 > z_{0.025} \rightarrow z = 1.96 \rightarrow \text{vero}$$

- Ripetere ora supponendo $\sigma=900$

E calcolare p value

$$\sigma^2 = 900 \rightarrow \sigma = 30$$

$$z = \frac{106 - 100}{\frac{30}{8}} \simeq 1.6$$

$1.6 < 1.96 \rightarrow$ non si può dire che è sopra la media

Se $\alpha = 1\%$ allora avrebbe accettato H_0

$$P \text{ value} = \bar{\alpha} = z_{\bar{\alpha}}$$

$$z_{\bar{\alpha}} = 1.6$$

È quindi

$$1 - \bar{\alpha} = \phi(z_{\bar{\alpha}})$$

$$\bar{\alpha} = 1 - \phi(1.6) = 0.0548$$

- Ipotesi di normalità è essenziale?

No siccome il campione è numeroso:

$$n = 64 > 30$$

- Se noi sappiamo che $\alpha = 1\%$

Rifiuto h_0

Quindi sappiamo che

$$\bar{\alpha} < 0.01$$

Possiamo provare a verificare per $\alpha = 0.5\%$

E rifacendo i calcoli notiamo che accettiamo h_0

$$\text{Quindi } 0.01 < \bar{\alpha} < 0.005$$

- 3) Un lotto viene ritenuto inaccettabile se 8% dei pezzi su 500
Su un campione di 100 pezzi se ne trovano 9 difettosi.

$$h_0: p \leq 0.08 \quad h_1: p > 0.08$$

Controlliamo se possiamo trasformare in $N(0, 1)$

$$n = 100 > 30, \quad np_0 = 8 > 5, \quad n(1 - p_0) = 92 > 5$$

Quindi posso fare test z approssimato

$$0.09 = \bar{x}_n$$

Usiamo la formula

$$\frac{\bar{x}_n - p_0}{\sqrt{\frac{p_0(1 - p_0)}{n}}} = z$$

Usiamo $\alpha = 5\%$

$$z_{\alpha} = 1.645$$

$$z = \dots = 0.3686$$

$z < z_{\alpha}$ quindi i dati non consentono di rifiutare h_0

- 4) Un gruppo di 6 pazienti per cura dimagrante

Questi risultati:

$$77, 87, 104, 98, 91, 78 = x_i$$

$$75, 88, 97, 99, 83, 70 = y_i$$

Con $\alpha = 5\%$

- a. E' la cura stata efficace?

Iniziamo a costruire campione differenze

$$d_i = x_i - y_i$$

$$-2, 1, -7, 1, -8, -8$$

Si può supporre che il peso è normalmente distribuito.

La cura è stata efficace se $x - y < 0$

$$h_0: m_{\phi} \geq 0 \quad h_1: m_{\phi} < 0$$

$$\bar{d}_n = 3.833$$

$$s_n^2 = 18.967$$

$$T = \frac{\frac{\bar{d}_n}{\frac{S_n}{\sqrt{n}}}}{\sqrt{6}} = \frac{-3.833 - H_0}{\sqrt{18.967}} * \sqrt{6} = -2.156$$

$$t_{5,0.05} = 2.015$$

$$t < -t_{5,\alpha} \rightarrow -2.156 < -2.015$$

Quindi la cura è stata efficace

b. Se si suppone un decremento di almeno 5kg?

$$H_0 \geq -5, \quad H_1 < -5$$

Rifiutiamo se

$$T = \frac{\bar{d} + 5}{\frac{S_6}{\sqrt{6}}} \sim t(5)$$

$$t = \dots = 0.656$$

$$0.656 < -t_{5,0.05} \rightarrow 0.656 < -2.015 \rightarrow \text{false}$$

5) I seguenti dati:

$$X = 42, 13, 37, 54, 23, 32, 45$$

$$Y = 67, 70, 53, 42, 37, 74, 53, 57, 64$$

Non hanno un legame ed hanno numerosità diverse

Quindi dobbiamo usare quella tabella

Si ipotizza che $m_x = m_y \rightarrow H_0$

Calcoliamo:

Possiamo applicare la tabella se

$$\frac{1}{2} < \frac{S_x^2}{S_y^2} < 2$$

$$S_x^2 = \frac{1}{n_x - 1} (\dots) \simeq 191.81$$

$$S_y^2 = \dots \simeq 157.78$$

$$\frac{1}{2} \leq \frac{191.81}{157.79} \leq 2 \rightarrow \text{vero}$$

Quindi possiamo applicare la tabella

$$S_p^2 = \frac{(n_x - 1)S_x^2 + (n_y - 1)S_y^2}{n_x + n_y - 2}$$

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n_x} + \frac{1}{n_y}}} \sim t(n_x + n_y - 2)$$

E si rifiuta se

$$|t| = |T| > t_{n_x+n_y-2, \frac{\alpha}{2}}$$