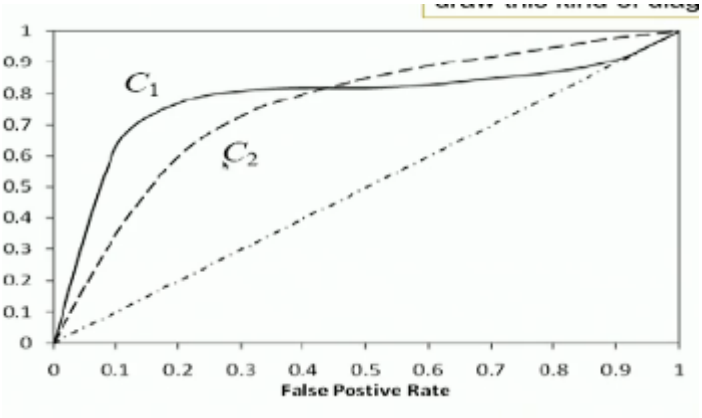
- Legge di moore: nel giro di ogni anni il numeri di transitori si raddoppiano
- Il machine learning si divide in
  - Apprendimento supervisionato
    Il dato si porta dietro già la risposta umana, già etichettato
    - Classificazione
      - Classificazione spam oppure no
      - Alberi di decisione
        - Goal: fare un modello di classificazione che può predire una classe di una nuova istanza
          - Correlare attributi => classe
          - Noi diamo in input dati labellati, siamo nel supervisioned
        - A seconda dell'output, può essere sia usato per la regressione che regressione
          - Classificazione: che tipo di classe/approvato
          - Regressione: valore numerato
        - Sono molto efficienti e buon performanti, sopratutto in linguaggio tabellare (non naturale)
      - KNN:
        -
          - E' un algoritmo, che non costruisce un modello
          - abbastanza lento durante la classificazione
          - Non abbiamo spazio del modello, ma quello del training set
          - E' abbastanza spiegabile, quindi so spiegare il perchè della classificazione
        - Quando dobbiamo classificare una nuova entità, noi andiamo a cercare le k entità più vicine al dato
          - E poi scegliamo la maggioranza della classe, e quella sarà l'etichetta della nuova entità
      - Combining classifier
        - Bagging
          - Un metodo per creare nuove entità nel training set
          - Praticamente prendiamo casualmente delle entità da un set, in maniera casuale, senza toglierlo dall'originale
            1/3 duplicati/mancanti
            E poi per ognuno abbiamo 1 classificatore

        - Questo funziona quando aiuta per i modelli instabili
          Siccome facciamo K tentativi con k dataset semi diversi e poi sceglieremo il migliore dei K
          Spiegato: faccio 8 dataset, per ogni dataset lo alleno con 8 classificatori, poi se voglio classificare un entità
          Do a tutti i 8 classificatori con 8 dataset semi diversi l'entità, e prendo l'output più comune
    - Boosting
        - L'output del modello, lo ridiamo subito come input del modello, sperando che i pesi cambiano bene
        - Se il dataset è fatto male, questo è molto suscettibili
            - E non è ottimale contro gli algoritmi stabili
    - Random forest
        - Fare tanti decision tree insieme che sono stati allenati su subset differente di dati e features
        - Ed il testing lo faccio come bagging: prendo la maggioranza
            - Da 1 a T alberi che vogliamo
              Faccio il bagging di nuovi deck
              E poi faccio decision tree però quando devo scegliere l'attributo, ci aggiungo un fattore casuale
- Modi per valutare il modello di classificatore:
    - Accuracia
        - Numero corretto classificazione / numero test
        - Una alternativa è la matrice di confusione
            - Quanti falsi positivi, falsi negativi, ecc
              E da qui escono le metrice:
            - Precision (specialità): numero di true positivi fratto true positivi + falsi positivi
            - Recall (sensibilità): come precision ma invece falsi negativi sotto
              E' possibile combinare precision e recall facendo la media armonica della precision e recall (2pr)/p+r
              Disolito si testano più di questi test per l'accuracia, e si mettono in un grafo. Quello che ha AUC (area under the

curve) più alta viene preso



    - Robustezza
        - Come si comporta con dati mancanti?
    - Scalabilità
        - Quando è efficace più diventa grande
    - Interpretabilità
        - Scatola nera?
    - Quanto è compatto il modello
- Regressione
    - Predizione della temperatura (valore)
- Self-supervised learning
  Inizio dai modelli supervisionati, e poi li faccio funzionare sui dati non-etichettati
  LLM rientrano in questo

- Apprendimento non supervisionato
  Qui la macchina non sa il risultato
    - Clustering
        - cerchiamo di raggruppare dati delle features (n piccolo) cercando relazioni
        - Mettere etichette sulle persone
    - Dimension reduction
        - Togliere delle features nei dati, o fare features di dipendenza
        - Disolito si usa con clustering
    - Anomaly detection
        - Stiamo andando verso un guasto nel sistema? Crash?
        - Poter individuare il raro
- Semi-supervisionato
    - Inizialmente c'è una fase supervisionata, e poi si va unserpevisionata
        - Es. google foto
- Reinforcement learning

        - Capacità di scegliere da soli, dato un ambiente, ed ottengono il reward attraverso una funzione
- in qualunque caso, l'output di un modello di ML è un programma stesso
    - Nel ML, nella maggior parte, il risultato è una black box
        - Per via di questo è difficile da valutare (no inferenze)
    - Quindi, siccome è difficile valutare, bisogna fare il training e validation set
        - Anche se passa il validation set, non vuol dire che funziona
        - Questo chiamato cross-validation test
            - K-Fold strategy:
                - Fai X gruppi
                - Poi per ogni gruppo - qualcuno fai training
                - E poi su quei - qualcuno fai il test set
        - Il validation set viene anche usato per estimare gli hyperparametri
            - Si utilizza prima del training set per decidere i treshold esempio, quanto grande rete neurale, ecc
- Nel machine learning, nella maggior parte una volta che hai addestrato il modello, non continuerà a migliorare
    - Questo vuol dire ricominciare da 0
    - Se provi a ri-allenare, spesso il modello si dimentica le cose di prima
    - Esistono 2 modi per dare dataset:
        - Batch-learning, te dai tutti i dadi in 1 botta
            - Efficente, molto costosa e se perdi, perdi tanto
        - Online learning, spezzetti un pò per volta
            - Qui bisogna stare attenti che non si dimentica ciò che ha fatto prima
    - Non sempre il modello deve essere gigante, a volte anche piccolo basta
        - A volte il ML non è nemmeno necessario
    - Problemi di ML:
        - Non ho abbastanza dati
        - Non ho dati per le situazioni corrette/non rappresentano la verità
        - Non ho tutti i dati corretti
        - Diamo features inutili
        - Over/under fitting
        - Problemi etici (come viene usato ML, come viene preso dataset, rimpiazza umani)